ET-BERT:用于加密流量分类的带有预训练转换器的上下文化数据报表示

林新杰1,2，熊刚1,2，沟高鹏1,2，李震1,2，石俊正1，于静1,2 *
1中国科学院信息工程研究所，北京2中国科学院大学网络安全学院，北京

[摘要]

加密流量分类需要从内容不可见和不均衡的流量数据中获取判别性和鲁棒性的流量表示来进行准确分类，这是实现网络安全和网络管理的一项挑战，但也是必不可少的。现有解决方案的主要局限在于高度依赖深度特征，而深度特征过于依赖数据大小，难以在不可见数据上泛化。如何利用开放域未标记的交通数据来学习具有较强泛化能力的表示，仍然是一个关键的挑战。在本文中，我们提出了一种新的流量表示模型，称为来自变压器的加密流量双向编码器表示(ET-BERT)，该模型从大规模未标记数据中预训练深度上下文化数据报级表示。预训练的模型可以在少量特定于任务的标记数据上进行微调，并在五个加密流量分类任务中实现最先进的性能，显著地将ISCX-VPN-Service的F1提高到98.9%(5.2%↑)，跨平台(Android)提高到92.5%(5.4%↑)，CSTNET-TLS的F1提高到1.3到97.4%(10.0%↑)。值得注意的是，我们通过分析密码的随机性提供了对经验上强大的预训练模型的解释。它为我们理解加密流量上的分类能力边界提供了见解。代码可从https://github.com/linwhitehat/ET-BERT获得。

CCS概念

· 信息系统→流量分析; · 安全与隐私→网络安全; · 计算方法学→人工智能。

关键词

加密流量分类，预训练，变压器，掩码BURST模型，同源BURST预测

ACM参考格式:

林新杰1,2，熊刚1,2,gou高鹏1,2，李震1,2，石俊正1，于静1,2 *。2022. ET-BERT:用于加密流量分类的带有预训练转换器的上下文化数据报表示。《ACM网络会议2022 (WWW’22)论文集》，2022年4月25日至29日，法国里昂。ACM，美国纽约，10页。https://doi.org/10.1145/3485447.3512217

*通讯作者。

This work is licensed under a Creative Commons Attribution International 4.0 License.

WWW’22, April 25–29, 2022, Lyon, France ©2022 Copyright held by the owner/author(s). ACM ISBN 978-1-4503-9096-5/22/04. https://doi.org/10.1145/3485447.3512217

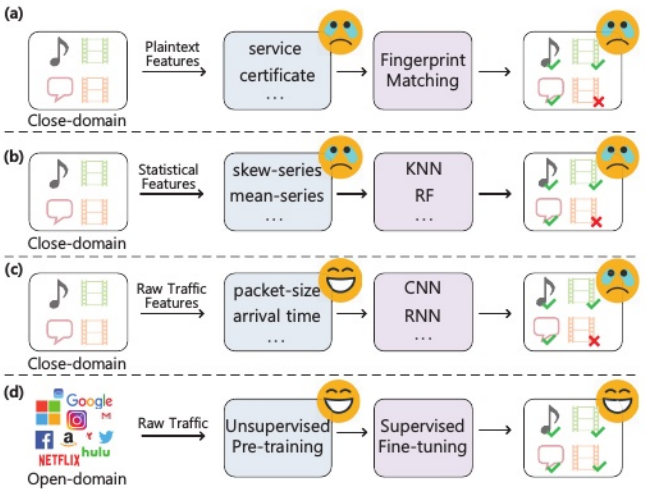

图1:四种主要的加密流量分类方法:(a)基于明文特征的指纹匹配。(b)基于统计特征的机器学习。(c)基于原始流量特征的ML. (d)基于原始流量的预训练。

1 介绍

网络流量分类旨在识别来自各种应用程序或web服务的流量类别，是网络管理和网络安全中的一项重要技术[4,32]。近年来，流量加密被广泛用于保护互联网用户的隐私和匿名性。然而，由于恶意流量和网络犯罪分子可以通过Tor、VPN等增强隐私的加密技术来逃避监控系统，这也给流量分类带来了巨大的挑战。传统的从有效载荷中捕获数据包中的模式和关键字的方法，称为深度包检测(DPI)，无法应用于加密流量。此外，由于加密技术的快速发展，针对特定类型加密流量的流量分类方法不能很好地适应新的环境或不可见的加密策略[27]。因此，如何在多样化的加密流量中捕捉隐含的、鲁棒的模式，支持准确的、通用的流量分类，是实现高网络安全性和有效网络管理的必要条件。

为了解决上述问题，加密流量分类方面的研究随着时间的推移有了显著的发展，如图1所示。早期的工作[35]利用加密流量(如证书)中剩余的明文来构造指纹并进行指纹匹配进行分类(图1(a))。然而，这些方法不适用于新出现的加密技术(例如TLS 1.3)，因为明文变得更加稀疏或

混淆。为此，一些作品[25,34]提取了统计特征，并采用经典的机器学习算法来处理没有明文的加密流量(图1(b))。这些方法高度依赖专家设计的特征，泛化能力有限。最近，深度学习方法[19,20]自动从原始流量中学习复杂的模式(图1(c))，并取得了显著的性能提升。然而，这些方法高度依赖于标记训练数据的数量和分布，容易造成模型偏差，难以适应新出现的加密。

近年来，预训练模型在自然语言处理[6]、计算机视觉[8]等广泛的领域都有很大的突破[2,17]。基于预训练的方法采用大量未标记数据来学习无偏数据表示。通过对有限数量的标记数据进行微调，可以很容易地将这种数据表示转移到下游任务中。在加密流量分类领域，最新的工作[12]直接应用了预训练技术，在VPN流量分类上得到了明显的改进，但缺乏针对流量设计的预训练任务和合理的输入表示来证明预训练模型的效果。

在本文中，我们提出了一种新的用于分类加密流量的预训练模型，称为加密流量双向编码器表示从变压器(ET-BERT)。它旨在从大规模未标记的加密流量中学习通用流量表示(图1(d))。我们首先提出了一个原始流量表示模型，将数据报转换为类似语言的令牌进行预训练。每个交通流由一个传输引导结构表示，表示为BURST，它作为输入。提出的框架包括两个阶段:预训练和微调。具体而言，具有Transformer结构的预训练网络通过对大规模未标记加密流量的自监督学习获得数据报级别的通用流量表示。其中，我们提出了两种新的预训练任务来学习流量特定模式:掩码BURST模型(MBM)任务捕获同一BURST中不同数据报字节之间的相关关系，并用上下文表示它们;同源BURST预测(Same-origin BURST Prediction, SBP)任务对前后BURST的传输关系进行建模。然后，ET-BERT结合特定的分类任务，利用少量特定任务的标记数据对参数进行微调。

本文的主要贡献总结如下:(1)我们提出了一个加密流量分类的预训练框架，该框架利用大规模未标记的加密流量来学习一系列加密流量分类任务的通用数据报表示。(2)我们提出了两个流量特定的自监督预训练任务，如掩码BURST模型和同源BURST预测，它们捕获字节级和BURST级上下文关系，以获得通用的数据报表示。(3) ET-BERT具有很强的泛化能力，在通用加密应用分类、加密恶意软件分类、VPN上加密流量分类、Tor上加密应用分类等5个加密流量分类任务上实现了新的最先进的性能。基于TLS 1.3的加密应用分类，并显著优于现有作品，分别提高5.4%、0.2%、5.2%、4.4%、10.0%。

同时，我们对预训练模型的强大性能进行了理论解释和分析。

2 相关工作

2.1 加密流量分类

指纹构建。与明文流量下的包检测方法不同，当流量被加密时，这种方法会失败，一些研究建议使用未加密的协议字段信息。FlowPrint[35]提取设备、证书、大小和时间特征来表示每个流量，并通过聚类和交叉关联构建指纹库，实现高效的流量分类。然而，这些指纹在虚拟通信网络中很容易被篡改，失去其正确的含义，而我们的模型不依赖于任何明文信息。

统计方法。大多数对加密流量的研究都是利用流量的统计特性来独立于流量加密。AppScanner[34]利用数据包大小的统计特征来训练随机森林分类器，而BIND[1]也利用了时间性的统计特征。然而，很难设计通用的统计特征来应对不断变得复杂的海量应用程序和网站，而我们的模型不需要依赖于人为设计的特征。

深度学习模型。使用监督深度学习的加密流量分类已经成为一种流行的方法，它可以自动提取判别特征，而不是依赖于人工设计。DF[33]使用卷积神经网络(cnn)， FS-Net[20]使用递归神经网络(rnn)从加密流量的原始数据包大小序列中自动提取表征，而Deeppacket[23]和TSCRNN[19]则对原始有效负载进行表征。然而，这种方法依赖于大量的监督数据来捕获有效特征，从而在不平衡数据中学习有偏见的表征，而我们的模型不依赖于大量的标记数据。

2.2 预训练模型

在自然语言处理中，基于变形金刚的深度双向预训练模型对于多任务的效果最好。有了这种表示类型和结构，RoBERTa[22]使用动态掩蔽，ALBERT[16]提出句子顺序预测，通过推进无监督任务来提高性能。预训练模型的扩展包括知识增强和模型压缩，ERNIE[40]引入实体知识来提高语言理解;而蒸馏器[28]通过知识蒸馏技术减少了网络层和参数的数量，显著加快了模型训练速度，但性能略有下降。此外，预训练模型在视觉语言和计算机视觉等跨领域的广泛应用证明了它们利用未标记数据来帮助学习有限标记数据上的鲁棒特征表示的优势。

在加密流量分类中，尽管有效载荷没有语义，但Sengupta等人[29]利用不同密文之间的随机性差异来区分不同的应用，这表明加密流量不是完全随机的，存在隐式模式。PERT[12]首先应用预训练模型将ALBERT迁移到加密流量分类和

在F1上的ISCX-VPN-Service[9]中实现了93.23%的性能。然而，根据我们在4.2节中的实证研究，它缺乏针对加密流量表示和相应的预训练任务的特定设计，这限制了它在新加密技术(例如TLS 1.3)上的泛化能力。考虑到流量传输的结构模式和数据包有效载荷的双向关联，我们设计了两个预训练任务，然后使用两种微调策略来更好地拟合流量分类任务。

3 ET-BERT

3.1 模型架构

在本文中，我们的目标是学习通用的加密流量表示，并在不同的场景(例如应用程序、加密协议或服务)中对它们进行分类。为此，我们提出的预训练策略包含两个主要阶段:用于学习具有大规模未标记数据的通用加密流量表示的预训练，以及用于调整针对特定下游任务的预训练模型的微调。在预训练阶段，给定未标记的交通流，预训练模型输出数据报级别的通用流量表示。在微调阶段，给定目标特定的标记数据包或流，微调模型预测其类别。

加密流量与自然语言和图像有很大不同，因为它不包含人类可理解的内容和明确的语义单位。为了有效地利用预训练技术进行加密流分类，我们在ET-BERT中主要提出了三个主要组成部分，如图2所示:

(1)提出Datagram2Token方法(第3.2节)，将加密流量转换为模式保留令牌单元进行预训练;
(2)然后提出两个预训练任务，即蒙面BURST模型和同源BURST预测，从转换上下文而不是语义上下文中学习上下文化的数据报表示(第3.3节);(3)为了适应不同的流量分类场景，我们进一步提出了两种微调策略，例如针对单包分类的包级微调和针对单流分类的流级微调(第3.4节)。

ET-BERT的主要网络结构由多层双向变压器块[36]组成。每个块由多头自关注层组成，捕获数据报中编码流量单元之间的隐式关系。在这项工作中，网络架构由12个变压器块组成，每个自注意层中有12个注意头。每个输入令牌H的维数设置为768，输入令牌的个数为512。

3.2 Datagram2Token流量表示

在真实的网络环境中，海量的流量中包含了不同类别(如不同的应用、协议或服务)的各种流量，很难学习到一种稳定的、判别性的流量表示。因此，在表示流量之前，我们首先将具有相同IP、端口和协议的流从迹线中分离出来。因此，每个拆分的流都来自包含完整流会话的同一流量类别。为了进一步将流转换为类似于自然语言的类词令牌，我们提出了一个Datagram2Token模块，该模块由三个过程组成:(1)BURST发生器在一个会话流中提取持续的服务器到客户端或客户端到服务器数据包，称为BURST[26,31]，以表示会话的部分完整信息。(2)然后BURST2Token过程通过双图模型将每个BURST中的数据报转换为令牌嵌入。同时，这个过程也将BURST分成两个部分，为预训练任务做准备。(3)最后，Token2Emebdding将每个token的token嵌入、位置嵌入和分割嵌入连接起来，作为预训练的输入表示。

3.2.1 BURST发生器。BURST被定义为一组时间相邻的网络数据包，这些数据包来自单个会话流中的请求或响应。脉冲序列从应用层的角度描述了网络流传输的模式。在应用层，由于web服务的个性化，网页之间的文档对象模型(DOM)树变得多样化。由于客户端渲染过程将web数据划分为不同的对象(例如文本和图像)，DOM结构生成语义感知的片段，并下意识地影响客户端的资源请求。每个生成的片段形成一个BURST网络，该网络包含来自DOM结构的具有特定类型的完整内容部分。我们提取脉冲作为预训练模型的输入。

对于BURST，我们关心的是数据包的源和目的地。给定一个来自包捕获文件的跟踪作为一个序列trace = {$flow_i$，$i \in N^+$}，其中flow ={p_j，$j \in N^+$}是一个会话流，由一个五元组(IPsrc:PORTsrc, IPdst:PORTdst, Protocol)标识的源到目的数据包p组成。BURST定义为:

$$BURST = \begin{cases} B^{src} = \{p_m^{src}, m \in \mathbb{N}^+\} \\ B^{dst} = \{p_n^{dst}, n \in \mathbb{N}^+\} \end{cases} \quad (1)$$

其中m, n分别表示源到目的和目的到源的最大单向数据包数。

3.2.2 BURST2Token。为了将BURST表示转换为预训练的token表示，我们将十六进制BURST分解为一个单位序列。

为此，我们使用双元图对十六进制序列进行编码，其中每个单元由两个相邻的字节组成。然后我们使用字节对编码(Byte-Pair Encoding)进行记号表示，其中每个记号单位的范围从0到65535，字典大小|V |最大表示为65536。此外，我们还为训练任务添加了特殊令牌[CLS]、[SEP]、[PAD]和[MASK]。每个序列的第一个令牌总是[CLS]，与该令牌关联的最终隐藏层状态用于表示分类任务的完整序列。令牌[PAD]是满足最小长度要求的填充符号。BURST的子BURST对将用[SEP]分隔。令牌[MASK]在预训练期间出现，以学习流量的上下文。

如图2所示，对于SBP任务，我们将一个BURST平均分为两个子BURST。我们通过特殊标记[SEP]和段嵌入来区分子BURST，表明它属于段A还是段B。我们将段A表示为sub-$BURST^A$，段B表示为sub-$BURST^B$。

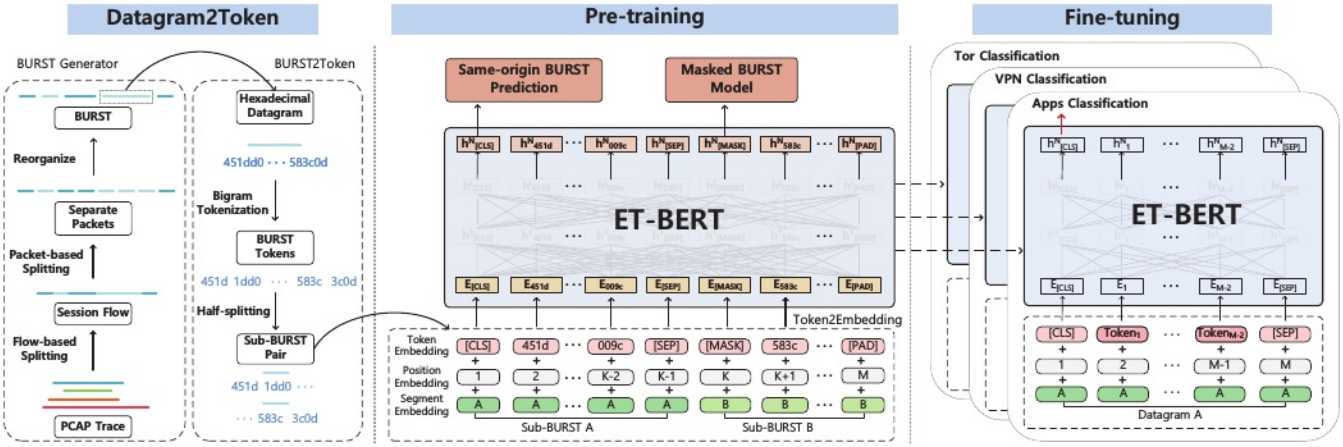

图2:ET-BERT框架概述。

3.2.3 Token2Embedding。在BURST2Token中，我们通过三种嵌入方法来表示每个token: token嵌入、位置嵌入和段嵌入。完整的令牌表示为由上述三种嵌入叠加而成。在这项工作中，我们将完整的标记化数据报作为原始输入。第一组嵌入向量被随机初始化，其中嵌入维数为D = 768。经过N次Transformer编码后，我们得到了最终的token嵌入。

令牌嵌入。如图2所示，第3.2.2节中从查找表中学习的令牌的表示称为令牌嵌入Etoken。输入令牌的最终隐藏向量为Etoken$\in_R^H$，其中嵌入维度H被设置为768。

位置嵌入。由于交通数据的传输与顺序有很强的相关性，我们使用位置嵌入来确保模型学会通过相对位置来关注令牌的时间关系。我们为每个输入令牌分配一个h维向量，用于表示其在序列中的位置信息。我们将位置嵌入表示为Epos$\in_R^H$，其中嵌入维数H设置为768。

段嵌入(Segment Embedding)。如3.2.2节所述，子BURST的分段嵌入记为Eseд$\in_R^H$，其中嵌入维数H设为768。在微调阶段，我们将数据包或流表示为分类任务的一个段。

3.3 预训练ET-BERT

我们提出的两个预训练任务通过预测掩码令牌来捕获流量字节之间的上下文关系，以及通过预测同源BURST来捕获正确的传输顺序。详细的过程如图2中间所示。

蒙面BURST模型。这个任务类似于BERT[6]使用的掩码语言模型(mask Language Model)。关键的区别在于，没有明显语义的流量令牌被合并到ET-BERT中，用于捕获数据报字节之间的依赖关系。在预训练期间，输入序列中的每个令牌以15%的概率被随机屏蔽。作为被选中的token，我们分别以80%的概率用[MASK]替换它，或者以10%的概率随机选择一个token来替换它，或者保持不变。

由于被屏蔽的令牌被特殊的令牌[MASK]取代，ET-BERT被训练来根据上下文预测被屏蔽位置的令牌。受益于深度双向表征这个任务带来的tion，我们为输入序列x随机屏蔽k个token，我们使用负对数似然作为我们的损失函数，并将其正式定义为:

$$L_{MBM} = -\sum_{i=1}^{k} \log(P(MASK_i = token_i|\bar{X};\theta)) \quad (2)$$

式中θ表示ET-BERT的可训练参数集。概率P由Transformer编码器用θ来建模。X^-是掩码后X的表示，$MASK_i$表示掩码序列中i_{th}位置的掩码。

同源BURST预测。BURST在网络流量中的重要性已在前一节中声明，我们的目的是通过捕获BURST中数据包的相关性来更好地学习流量表示。此外，我们考虑了BURST结构与网页内容之间的紧密关系，这能够传达不同类别流量产生的BURST之间的差异。例如，通过对具有不同DOM结构的社交网站分别加载内容，例如按文本、图像、视频的顺序和按图像、文本、视频的顺序，在流量中存在差异。针对域内指纹的研究[37]也证实了这一现象。

我们通过同源BURST预测(SBP)任务来学习BURST内部数据包之间的依赖关系。对于这项任务，使用二元分类器来预测两个子BURST是否来自相同的BURST来源。具体来说，当为每个子BURST对选择sub-BURST^{A}和sub-BURST^{B}时，50%的时间sub-BURST^{B}是sub-BURST^{A}之后的下一个实际的子BURST, 50%的时间它是来自其他BURST的随机子BURST。对于包含子BURST对B_j=(sub-B^A_j,sub-B^B_j)及其基本真理$label_j\in[0,1]$的给定输入(0表示成对的子burst, 1表示未成对的子burst)。

$$L_{SBP} = -\sum_{j=1}^{n} \log(P(y_j|B_j;\theta)) \quad (3)$$

总的来说，最终的预训练目标是上述两个损失之和，定义为:

$$L = L_{MBM} + L_{SBP} \tag{4}$$

预训练数据集。在这项工作中，大约30GB的未标记交通数据被用于预训练。该数据集包含两部分:(1)来自公共数据集的约15GB流量[9,30];(2)中国科技网(CSTNET)下被动采集流量约15GB。此外，数据集还包含丰富的网络协议，如基于UDP传输QUIC的新型加密协议、传输层安全、文件传输协议、超文本传输协议、Secure Shell等，这些都是常用的网络协议。

3.4 微调ET-BERT

微调可以很好地服务于下游分类任务，因为:(1)预训练表示是流量类无关的，可以应用于任何类别的流量表示;(2)由于预训练模型的输入是在数据报字节级别，需要对数据包和流进行分类的下游任务可以转换成相应的数据报字节令牌，由模型进行分类;(3)预训练模型输出的特殊[CLS]令牌对整个输入流量的表示进行建模，可以直接用于分类。

由于微调和预训练的结构基本相同，我们将特定于任务的数据包或流表示输入到预训练的ET-BERT中，并在端到端模型中微调所有参数。在输出层，将[CLS]表示提供给多类分类器进行预测。我们提出了两种微调策略来适应不同场景的分类:(1)将数据包级别作为输入，专门用于实验ET-BERT是否可以适应更细粒度的流量数据，如ET-BERT(数据包);(2) flow level作为输入，致力于公平客观地比较ET-BERT与其他方法，如ET-BERT(flow)。两种微调模型的主要区别在于输入流量的信息量。我们使用流中M个连续数据包的缝合数据报作为输入数据，在我们的方法中M被设置为5。流量数据处理在4.1节中有详细描述。

与预训练相比，微调的成本相对便宜，单个GPU就足以完成微调任务。

4 实验

在本节中，我们通过5个加密流分类任务(4.1节)来证明ET-BERT在解决不同加密场景和数据分布不均衡问题上的有效性。然后，我们将我们的模型与11种方法(第4.2节)进行比较，并对模型的关键组成部分进行消融分析(第4.3节)。我们进一步对ET-BERT获得的卓越性能(第4.4节)和处理少量样本的能力(第4.5节)进行了解释性分析。

4.1 实验设置

4.1.1数据集和下游任务。为了评估ET-BERT的有效性和泛化性，我们在6个公共数据集上进行了5个加密流量分类任务的实验

表1:数据集的统计信息。

Task	Dataset	#Flow	#Packet	#Label
GEAC	Cross-Platform(iOS) [35]	20,858	707,717	196
	Cross-Platform(Android) [35]	27,846	656,044	215
EMC	USTC-TFC [39]	9,853	97,115	20
ETCV	ISCX-VPN-Service [9]	3,694	60,000	12
	ISCX-VPN-App [9]	2,329	77,163	17
EACT	ISCX-Tor [10]	3,021	80,000	16
EAC-1.3	CSTNET-TLS 1.3 (Ours)	46,372	581,709	120

以及一个新提出的数据集。任务和相应的数据集如表1所示。

任务1:通用加密应用分类(General Encrypted Application Classification, GEAC)任务旨在根据标准加密协议对应用流量进行分类。我们在跨平台(iOS)[35]和跨平台(Android)[35]上进行测试，分别包含196个和215个应用程序。iOS应用和Android应用分别来自美国、中国和印度的前100名应用。这个数据集拥有最多的类别和所有类别的长尾数据分布。

任务2:加密恶意软件分类(EMC)是由恶意软件和良性应用[39]组成的加密流量的集合。数据集USTC-TFC[39]包含10类良性流量和10类恶意流量。

任务3:ETCV (encryption Traffic Classification on VPN)任务对使用VPN进行网络通信的加密流量进行分类。VPN在绕过审查以及访问地理锁定服务方面很受欢迎，由于其协议混淆，这很难检测到。我们使用通常比较的ISCX-VPN[9]，它是由加拿大网络安全研究所在VPN和非VPN中捕获的6个通信应用程序组成的。为了测试ET-BERT的服务和应用，我们进一步将数据集按服务和应用进行分类，形成了包含12个类别的ISCX-VPN-Service数据集和包含17个应用的ISCX-VPN-App数据集。

任务4:Tor上的加密应用分类(EACT)任务旨在对使用洋葱路由器(Tor)的加密流量进行分类，以增强通信隐私。数据集[10]称为ISCX-Tor，包含16个应用程序。这种流量通过分布式路由网络混淆了发送方和接收方之间的通信，从而进一步模糊了流量的行为，这对流量分类来说更具挑战性，因为流量的模式提取变得更加困难。

任务5:基于TLS 1.3的加密应用分类(EAC-1.3)任务旨在对基于新加密协议TLS 1.3的加密流量进行分类。数据集是我们从2021年3月到7月在CSTNET下收集的120个应用程序，命名为CSTNET-TLS 1.3。正如我们所知，这是迄今为止第一个TLS 1.3数据集。应用程序是从部署了TLS 1.3的Alexa Top-5000[3]获得的，我们通过服务器名称指示(SNI)标记每个会话流。在CSTNET-TLS 1.3中，由于TLS 1.3的兼容性，SNI仍然可以访问。ECH机制将在将来禁用SNI并损害标记的准确性，但我们将在第5节中讨论一些克服它的想法。

表2:跨平台、ISCX-VPN-Service和ISCX-VPN-App数据集的比较结果。

Dataset	Cross-Platform(iOS)				Cross-Platform(Android)				ISCX-VPN-Service				ISCX-VPN-App			
Method	AC	PR	RC	F1	AC	PR	RC	F1	AC	PR	RC	F1	AC	PR	RC	F1
AppScanner[34]	0.3205	0.2103	0.2173	0.2030	0.3868	0.2523	0.2594	0.2440	0.7182	0.7339	0.7225	0.7197	0.6266	0.4864	0.5198	0.4935
CUMUL[25]	0.2910	0.1917	0.2081	0.1875	0.3525	0.2221	0.2409	0.2189	0.5610	0.5883	0.5676	0.5668	0.5365	0.4129	0.4535	0.4236
BIND[1]	0.3770	0.2566	0.2715	0.2484	0.4728	0.3126	0.3253	0.3026	0.7534	0.7583	0.7488	0.7420	0.6767	0.5152	0.5153	0.4965
K-fp[11]	0.2155	0.2037	0.2069	0.2003	0.2248	0.2113	0.2104	0.2052	0.6430	0.6492	0.6417	0.6395	0.6070	0.5478	0.5430	0.5303
FlowPrint[35]	0.9254	0.9438	0.9254	0.9260	0.8698	0.9007	0.8698	0.8702	0.7962	0.8042	0.7812	0.7820	0.8767	0.6697	0.6651	0.6531
DF[33]	0.3106	0.2232	0.2179	0.2140	0.3862	0.2595	0.2620	0.2527	0.7154	0.7192	0.7104	0.7102	0.6116	0.5706	0.4752	0.4799
FS-Net[20]	0.3712	0.2845	0.2754	0.2655	0.4846	0.3544	0.3365	0.3343	0.7205	0.7502	0.7238	0.7131	0.6647	0.4819	0.4848	0.4737
GraphDApp[31]	0.3245	0.2450	0.2392	0.2297	0.4031	0.2842	0.2786	0.2703	0.5977	0.6045	0.6220	0.6036	0.6328	0.5900	0.5472	0.5558
TSCRNN[19]	-	-	-	-	-	-	-	-	-	0.9270	0.9260	0.9260	-	-	-	-
Deeppacket[23]	0.9204	0.8963	0.8872	0.9034	0.8805	0.8004	0.7567	0.8138	0.9329	0.9377	0.9306	0.9321	0.9758	0.9785	0.9745	0.9765
PERT[12]	0.9789	0.9621	0.9611	0.9584	0.9772	0.8628	0.8591	0.8550	0.9352	0.9400	0.9349	0.9368	0.8229	0.7092	0.7173	0.6992
ET-BERT(flow)	**0.9844**	0.9701	0.9632	0.9643	**0.9865**	0.9324	**0.9266**	**0.9246**	0.9729	0.9756	0.9731	0.9733	0.8519	0.7508	0.7294	0.7306
ET-BERT(packet)	0.9810	**0.9757**	**0.9772**	**0.9754**	0.9728	**0.9439**	0.9119	0.9206	**0.9890**	**0.9891**	**0.9890**	**0.9890**	**0.9962**	**0.9936**	**0.9938**	**0.9937**

表3:ISCX-Tor、USTC-TFC和CSTNET-TLS 1.3数据集的比较结果。

Dataset	ISCX-Tor				USTC-TFC				CSTNET-TLS 1.3			
Method	AC	PR	RC	F1	AC	PR	RC	F1	AC	PR	RC	F1
AppScanner[34]	0.6722	0.3756	0.4422	0.3913	0.8954	0.8984	0.8968	0.8892	0.6662	0.6246	0.6327	0.6201
CUMUL[25]	0.6606	0.3850	0.4416	0.3918	0.5675	0.6171	0.5738	0.5513	0.5391	0.4942	0.5060	0.4904
BIND[1]	0.7185	0.4598	0.4515	0.4511	0.8457	0.8681	0.8382	0.8396	0.7964	0.7605	0.7650	0.7560
K-fp[11]	0.6472	0.5576	0.5849	0.5522	-	-	-	-	0.4036	0.3969	0.4044	0.3902
FlowPrint[35]	0.9092	0.3820	0.3661	0.3654	0.8146	0.6434	0.7002	0.6573	0.1261	0.1354	0.1272	0.1116
DF[33]	0.7533	0.6228	0.6010	0.5850	0.7787	0.7883	0.7819	0.7593	0.7936	0.7721	0.7573	0.7602
FS-Net[20]	0.6071	0.5080	0.5350	0.4590	0.8846	0.8846	0.8920	0.8840	0.8639	0.8404	0.8349	0.8322
GraphDApp[31]	0.6836	0.4864	0.4823	0.4488	0.8789	0.8226	0.8260	0.8234	0.7034	0.6464	0.6510	0.6440
TSCRNN[19]	-	0.9490	0.9480	0.9480	-	0.9870	0.9860	0.9870	-	-	-	-
Deeppacket[23]	0.7449	0.7549	0.7399	0.7473	0.9640	0.9650	0.9631	0.9641	0.8019	0.4315	0.2689	0.4022
PERT[12]	0.7682	0.4424	0.4446	0.4345	0.9909	0.9911	0.9910	0.9911	0.8915	0.8846	0.8719	0.8741
ET-BERT(flow)	0.8311	0.5564	0.6448	0.5886	**0.9929**	**0.9930**	**0.9930**	**0.9930**	0.9510	0.9460	0.9419	0.9426
ET-BERT(packet)	**0.9921**	**0.9923**	**0.9921**	**0.9921**	0.9915	0.9915	0.9916	0.9916	**0.9737**	**0.9742**	**0.9742**	**0.9741**

伦理方面的考虑。在本研究中，咨询了IRB，没有使用任何识别。此外，收集完全是被动的。我们已经遵守了收集数据的公司网络的用户协议。

4.1.2数据预处理。我们去掉了地址解析协议(ARP)和动态主机配置协议(DHCP)的数据包，它们与传输内容的具体流量无关。为了避免包头的影响，包头可能会在具有强识别信息(如IP和端口[18,23,38])的有限集合中引入偏置干扰，我们删除了TCP头中的以太网头、IP头和协议端口。在微调阶段，我们从所有数据集中的每个类中随机选择最多500个流和5000个数据包。每个数据集按照8:1:1的比例划分为训练集、验证集和测试集。

4.1.3评估指标和实现细节。我们通过四个典型指标来评估和比较我们模型的性能，包括准确性(AC)、精度(PR)、召回率(RC)和F1[35,42]。Macro Average[21]通过计算每一类数据的AC、PR、RC和F1的平均值，避免因多类数据之间的不平衡而导致结果偏倚。在预训练中，批大小为32，总步长为500,000。我们设置学习率为2×10^{-5}，预热比为0.1。我们用Adam W优化器对10个epoch进行微调，其中流级学习率设置为6×10^{-5}，包级学习率设置为2×10^{-5}。batch size为32,dropout rate为0.5。所有实验均使用Pytorch 1.8.0和UER[41]实现，使用NVIDIA Tesla V100S gpu进行。

4.2 与最先进方法的比较

我们将ET-BERT与各种最先进的(SOTA)方法进行了比较，包括(1)指纹构建方法:FlowPrint [35];(2)统计特征方法:AppScanner[34]、CUMUL[25]、BIND[1]和k-fingerprinting (K-fp) [11];(3)深度学习方法:deep Fingerprinting (DF)[33]、FS-Net [20]、GraphDApp[31]、TSCRNN[19]、Deeppacket [23];(4) 预训练方法:PERT[12]。实验结果如表2、表3所示。附加的比较研究见附录A.1。

geac。根据表2,ET-BERT(包)和ET-BERT(流)都明显优于所有方法。我们的模型在跨平台(iOS)和跨平台(Android)上分别获得了1.7%和5.4%的改进(例如PERT和FlowPrint)。FlowPrint利用包括证书字段在内的明文指纹，构建多维指纹库，用于应用识别。然而，ET-BERT学习

表4:ISCX-VPN-App数据集上ET-BERT关键成分消融研究。

	Method	SBP	MBM	PT-P	PT-B	FT-f	FT-cf	FT-P	AC	PR	RC	F1
	ET-BERT(packet)(full model)	✓	✓	×	✓	×	×	✓	**0.9471**	**0.9462**	**0.9412**	**0.9395**
1	w/o SBP	×	✓	×	✓	×	×	✓	0.9000	0.9142	0.9000	0.8998
2	w/o MBM	✓	×	×	✓	×	×	✓	0.8471	0.8666	0.8471	0.8462
3	w/o BURST	✓	✓	✓	×	×	×	✓	0.9235	0.9386	0.9235	0.9258
4	ET-BERT(flow)	✓	✓	×	✓	✓	×	×	0.8133	0.7661	0.7374	0.7387
5	concatenated-flow(cf)	✓	✓	×	✓	×	✓	×	0.8229	0.7488	0.6812	0.6961
6	w/o pre-training(packet)	×	×	×	×	×	×	✓	0.5882	0.6152	0.5882	0.5638

不依赖于任何明文字段的密文上的上下文关系。此外，我们的模型学习了交通传输结构的模式，这是PERT无法掌握的。

emc。从表3所示的USTC-TFC上的结果中，我们可以观察到所有方法的性能都不如我们的模型。我们的模型在F1上达到了99.30%的最佳性能。我们观察到，该数据集中的恶意流量在应用层中包含未加密的数据，这使得其他模型更容易利用这种明文进行更容易的分类。

ETCV ET-BERT在ISCX-VPN-Service和ISCX-VPN-App上比现有最先进的Deeppacket模型分别提高了5.69%和1.72%。这两个数据集都提出了不平衡的挑战，这在ISCX-VPN-App上更为严重。我们的模型和Deep-packet通过学习分组数据报之间的相关性来缓解数据不平衡的影响。此外，除了PERT方法外，ET-BERT在F1上的平均改进率分别为25.55%和42.89%，表明我们的模型即使在数据不平衡的情况下也具有较强的识别混淆流量的能力。

eact。如表3所示，在ISCX-Tor上的结果表明，ET-BERT比TSCRNN现有的最佳结果提高了4.41%。Tor中的初始流量不仅进行了多层加密，而且还进行了对抗性混淆。TSCRNN通过随机抽样丰富流来训练模型，同时利用包之间的内在关系来实现更好的分类。

每个-1.3。我们的模型比现有的技术水平提高了10.0%，从87.41%提高到表3所示的CSTNET-TLS 1.3的结果。TLS 1.3在提高传输安全性的同时，也对FlowPrint和Deeppacket提出了新的挑战。ET-BERT通过深度表示数据报，将F1推至97.41%。这表明TLS 1.3上加密的流量数据报仍然具有隐式模式，ET-BERT可以更好地利用这些模式进行分类。

4.3 消融研究

我们展示了消融结果，以验证每个组件对广泛比较的ISCX-VPN-App的贡献。为了公平地比较数据包和流量级别的微调方法，我们从每个类中随机选择最多100个数据包和流作为训练数据集。在表4中，PT- p和PT- b分别表示输入是随机选择的相邻数据包和我们在预训练(PT)中提出的BURST数据包。FT-f、FT-cf和FT- p分别表示在微调(FT)中使用流、连接流[12]和单个数据包。(1)在模型' 1-3 '中，我们评估了每个任务的影响和

表5对5个密码进行15次随机性检验的结果。

Ciphers/Tests	AES(GCM)	AES(CBC)	CHA20	ARC4	3DES
Monobit	0.7918	0.2585	0.9761	0.5687	0.4099
Block Frequency	0.6316	0.0791	0.0176	0.4821	0.6434
Independent Runs	0.8824	0.1672	0.8966	0.7052	0.4241
Longest Runs	0.7198	0.3148	0.5134	0.5156	0.2889
Spectral	0.6202	0.9707	0.9415	0.6729	0.5756
Overlapping Patterns(OP)	0.0519	0.9856	0.1002	0.9089	0.4762
Non OP	0.8148	0.1967	0.4445	0.0096	0.5156
Universal	0.8501	0.3277	0.1149	0.0416	0.3062
Serial	0.7690	0.4539	0.1600	0.6068	0.8381
Approximate Entropy	0.9239	0.5226	0.3371	0.3470	0.3611
Cumulative Sums	0.9496	0.4512	0.7355	0.1742	0.4043
Random Excursions(RE)	0.1811	0.1232	0.4112	0.9424	0.9091
RE Variant	0.4805	0.0119	0.9542	0.5978	0.9065
Matrix Rank	0.5674	0.4890	0.0880	0.0504	0.1447
Linear Complexity	0.6235	0.4519	0.7428	0.0952	0.9384

预训练的输入。“1”和“2”在F1上分别下降了3.97%和9.33%，表明这两个自监督任务都有利于为分类提供互补模式。此外，我们在' 3 '中输入数据包而不是BURST, F1分数降低了1.37%。实验证明，BURST结构可以学习报文之间的关系，从而更好地进行流分类。(2)在模型“4”和“5”中，我们评估了不同形式的微调流的效果。模型“4”使用连续的数据包作为输入，而模型“5”单独使用数据包作为输入，并在最终编码器层连接输出，就像PERT[12]一样。当我们从flow切换到concatenated-flow时，模型“5”的结果下降了4.26%。一个流的不同数据包是相互依赖的，我们对流进行分类的微调方法更有益。(3)我们移除预训练的模型来评估预训练的影响。根据模型‘6’，我们通过直接训练Transformer模型对标注数据进行监督学习，F1分数较ET-BERT显著下降了37.57%。

4.4 可解释性

4.4.1随机性分析。上述结果证明了ET-BERT算法的有效性和泛化性，因为加密有效载荷的密码具有不完全随机性。理想的加密方案使生成的消息承受最大可能的熵[5]。然而，这个假设并非如此

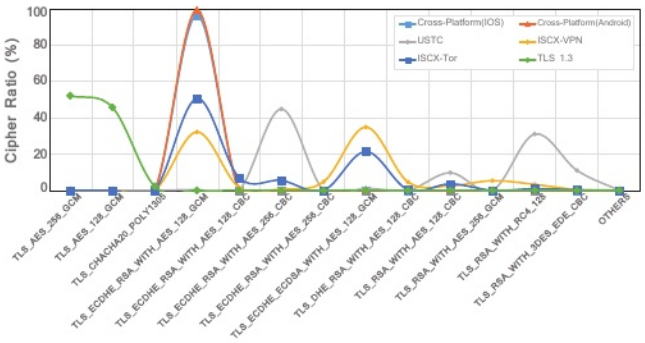

图3:密码在所有数据集中的分布

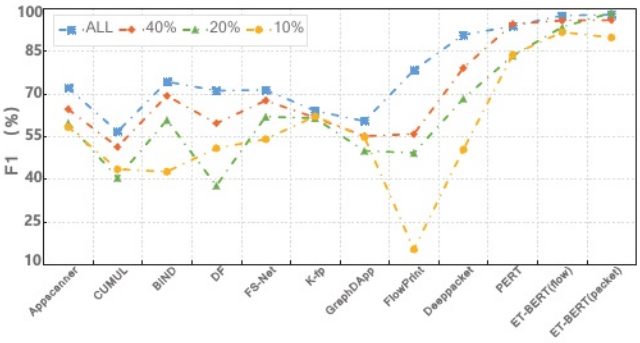

图4:Few-shot ISCX-VPN-App的对比结果。

在实践中是有效的，因为不同的密码实现具有不同程度的随机性[7]。我们通过15组统计检验[24]来评估本文中5个密码的强度，其中p值= 1表示序列的完全随机性。如表5所示，这些密码确实无法达到完全随机性。

4.4.2密码的影响。为了评估不同密码对ET-BERT的影响，我们分析了不同数据集上密码的使用。如图3所示，横坐标表示占前13种类型和其他类型的密码，纵坐标表示每种密码的百分比。ISCX-VPN、ISCX-Tor和USTC-TFC包含至少3个密码，包括RC4和3DES，随机性较弱，而其他数据集主要由一个密码组成。由表2和表3可知，在随机性较弱、波动较大的数据集上，ET-BERT的F1接近100%，ETCV平均为99.14%，EACT平均为99.21%，EMC平均为99.30%。

4.5 Few-shot Analysis

为了验证ET-BERT在少数镜头设置下的有效性和鲁棒性，我们在ISCX-VPN-Service上设计了不同数据比例的对比实验。我们将每个类别的数据大小设置为500，并随机选择40%，20%和10%的样本进行少镜头实验。在图4中，对比结果表明，预训练方法受数据大小减少的影响最小。40%、20%、10%数据量下的ET-BERT(包)F1得分分别为95.78%、98.33%、91.55%。我们的模型在所有方法中取得了最好的结果。相比之下，当样本量减少时，传统的监督方法(例如BIND、DF、FS-Net)表现出明显的F1性能下降，例如当样本量从全尺寸减少到10%时，Deeppacket的性能下降40.22%。这说明预训练方法更有效地解决了少射加密流量的分类问题。

5 讨论

在本节中，我们讨论了这项工作的一些局限性，以及它在诱导该领域进一步研究方面可能产生的潜在影响。概括性:由于互联网服务[13]内容随时间的变化而导致的加密流量的可变性，将挑战我们从固定数据中学习固定模式并随时间保持不变的方法的能力。随着使用和随着TLS 1.3的兴起，通过SNI标记加密流量将不可能。我们通过两种方式缓解了这种情况，以适应ECH机制，从而保证了通用性的测试，包括主动访问和使用唯一进程标识符进行标记。预训练安全性:虽然ET-BERT在各种加密流量场景下具有良好的鲁棒性和泛化性，但它依赖于干净的预训练数据。当攻击者故意添加低频子词作为“有毒”嵌入时，可以生成带有“后门”的有毒预训练模型，以迫使模型预测目标类，最终在特定分类任务上欺骗正常微调的模型[14,15]。然而，如何构建加密流量的“有毒”令牌，目前还没有研究。

6 结论

在本文中，我们提出了一种新的加密流量表示模型——ET-BERT，它可以从大规模的未标记数据中预训练深度上下文数据报级流量表示，然后通过对少量特定于任务的标记数据进行简单的微调，准确地对多个场景的加密流量进行分类。我们在5个公开可用的数据集和CSTNET收集的TLS 1.3数据集上综合评估了ET-BERT的泛化和鲁棒性。ET-BERT具有很强的泛化能力，在通用加密应用分类、加密恶意软件分类、VPN上的加密流量分类、Tor上的加密应用分类、基于TLS 1.3的加密应用分类，显著优于现有作品，分别提高5.4%、0.2%、5.2%、4.4%、10.0%。在未来，我们希望研究ET-BERT预测新类别样本和抵抗样本攻击的能力。

致谢

本工作得到国家重点研发计划项目(2021YFB3101400)和中国科学院战略重点研究计划(批准号:2021YFB3101400)的支持。xdc02040400。我们感谢匿名审稿人为我们改进本文所提供的富有成效的意见、更正和启发。我们也衷心感谢Magnus Almgren的指点以及Zhong Guan和Lulin Wang的写作帮助。

参考文献

[1] Khaled Al-Naami, Swarup Chandra, Ahmad M. Mustafa, Latifur Khan, Zhiqiang Lin, Kevin W. Hamlen, and Bhavani M. Thuraisingham. 2016. Adaptive Encrypted Traffic Fingerprinting with Bi-Directional Dependence. In the Annual Conference on Computer Security Applications. 177–188.

[2] Emily Alsentzer, John R. Murphy, Willie Boag, Wei-Hung Weng, Di Jin, Tristan Naumann, and Matthew B. A. McDermott. 2019. Publicly Available Clinical BERT Embeddings. In the Clinical Natural Language Processing Workshop. 72–78.

[3] Amazon. 2021. Alexa Top Sites. https://www.alexa.com/topsites/.

[4] Tomasz Bujlow, Valentín Carela-Español, and Pere Barlet-Ros. 2015. Independent Comparison of Popular DPI Tools for Traffic Classification. Computer Networks 76 (2015), 75–89.

[5] Thomas M. Cover and Joy A. Thomas. 2006. Elements of Information Theory (2. ed.).

[6] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 4171–4186.

[7] Ali Doganaksoy, Baris Ege, Onur Koçak, and Fatih Sulak. 2010. Cryptographic Randomness Testing of Block Ciphers and Hash Functions. Cryptology ePrint Archive (2010), 564.

[8] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. 2021. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In International Conference on Learning Representations.

[9] Gerard Draper-Gil, Arash Habibi Lashkari, Mohammad Saiful Islam Mamun, and Ali A. Ghorbani. 2016. Characterization of Encrypted and VPN Traffic using Time-related Features. In the International Conference on Information Systems Security and Privacy. 407–414.

[10] Arash Habibi Lashkari, Gerard Draper Gil, Mohammad Saiful Islam Mamun, and Ali A. Ghorbani. 2017. Characterization of Tor Traffic using Time based Features. In the International Conference on Information Systems Security and Privacy. 253–262.

[11] Jamie Hayes and George Danezis. 2016. K-fingerprinting: A Robust Scalable Website Fingerprinting Technique. In USENIX Security Symposium. 1187–1203.

[12] Hong Ye He, Zhi Guo Yang, and Xiang Ning Chen. 2020. PERT: Payload Encoding Representation from Transformer for Encrypted Traffic Classification. In ITU Kaleidoscopef: Industry-Driven Digital Transformation. 1–8.

[13] Marc Juárez, Sadia Afroz, Gunes Acar, Claudia Díaz, and Rachel Greenstadt. 2014. A Critical Evaluation of Website Fingerprinting Attacks. In the ACM SIGSAC Conference on Computer and Communications Security. 263–274.

[14] Nora Kassner and Hinrich Schütze. 2020. Negated and Misprimed Probes for Pretrained Language Models: Birds Can Talk, But Cannot Fly. In the Annual Meeting of the Association for Computational Linguistics. 7811–7818.

[15] Keita Kurita, Paul Michel, and Graham Neubig. 2020. Weight Poisoning Attacks on Pretrained Models. In the Annual Meeting of the Association for Computational Linguistics. 2793–2806.

[16] Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel, Piyush Sharma, and Radu Soricut. 2020. ALBERT: A Lite BERT for Self-supervised Learning of Language Representations. In International Conference on Learning Representations.

[17] Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. 2019. BioBERT: A Pre-trained Biomedical Lan-guage Representation Model for Biomedical Text Mining. Bioinformatics 36, 4 (2019), 1234–1240.

[18] Rui Li, Xi Xiao, Shiguang Ni, Haitao Zheng, and Shutao Xia. 2018. Byte Segment Neural Network for Network Traffic Classification. In International Symposium on Quality of Service. 1–10.

[19] Kunda Lin, Xiaolong Xu, and Honghao Gao. 2021. TSCRNN: A Novel Classification Scheme of Encrypted Traffic Based on Flow Spatiotemporal Features for Efficient Management of IIoT. Computer Networks 190 (2021), 107974.

[20] Chang Liu, Longtao He, Gang Xiong, Zigang Cao, and Zhen Li. 2019. FS-Net: A Flow Sequence Network For Encrypted Traffic Classification. In IEEE Conference on Computer Communications. 1171–1179.

[21] Chuan Liu, Wenyong Wang, Meng Wang, Fengmao Lv, and Martin Konan. 2017. An Efficient Instance Selection Algorithm to Reconstruct Training Set for Support Vector Machine. Knowledge-Based Systems 116 (2017), 58–73.

[22] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv preprint arXiv:1907.11692 (2019).

[23] Mohammad Lotfollahi, Mahdi Jafari Siavoshani, Ramin Shirali Hossein Zade, and Mohammdsadegh Saberian. 2020. Deep Packet: A Novel Approach for Encrypted Traffic Classification Using Deep Learning. Soft Computing 24 (2020), 1999–2012.

[24] National Institute of Standards and Technology. 2016. Random Bit Genera-tion: Guide to the Statistical Tests. https://csrc.nist.gov/Projects/Random-Bit-Generation/Documentation-and-Software/Guide-to-the-Statistical-Tests.

[25] Andriy Panchenko, Fabian Lanze, Jan Pennekamp, Thomas Engel, Andreas Zinnen, Martin Henze, and Klaus Wehrle. 2016. Website Fingerprinting at Internet Scale. In Annual Network and Distributed System Security Symposium.

[26] Andriy Panchenko, Lukas Niessen, Andreas Zinnen, and Thomas Engel. 2011. Website Fingerprinting in Onion Routing Based Anonymization Networks. In the Annual ACM Workshop on Privacy in the Electronic Society. 103–114.

[27] Shahbaz Rezaei and Xin Liu. 2019. Deep Learning for Encrypted Traffic Classification: An Overview. IEEE Communications Magazine 57, 5 (2019), 76–81.

[28] Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. 2019. DistilBERT, A Distilled Version of BERT: Smaller, Faster, Cheaper and Lighter. arXiv preprint arXiv:1910.01108 (2019).

[29] Satadal Sengupta, Niloy Ganguly, Pradipta De, and Sandip Chakraborty. 2019. Exploiting Diversity in Android TLS Implementations for Mobile App Traffic Classification. In The World Wide Web Conference. 1657–1668.

[30] Iman Sharafaldin, Arash Habibi Lashkari, and Ali A. Ghorbani. 2018. Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization. In the International Conference on Information Systems Security and Privacy. 108–116.

[31] Meng Shen, Jinpeng Zhang, Liehuang Zhu, Ke Xu, and Xiaojiang Du. 2021. Accurate Decentralized Application Identification via Encrypted Traffic Analysis Using Graph Neural Networks. IEEE Transactions on Information Forensics and Security 16 (2021), 2367–2380.

[32] Hongtao Shi, Hongping Li, Dan Zhang, Chaqiu Cheng, and Xuanxuan Cao. 2018. An Efficient Feature Generation Approach Based on Deep Learning and Feature Selection Techniques for Traffic Classification. Computer Networks 132 (2018), 81–98.

[33] Payap Sirinam, Mohsen Imani, Marc Juarez, and Matthew Wright. 2018. Deep Fingerprinting: Undermining Website Fingerprinting Defenses with Deep Learning. In the ACM SIGSAC Conference on Computer and Communications Security. 1928–1943.

[34] Vincent F. Taylor, Riccardo Spolaor, Mauro Conti, and Ivan Martinovic. 2018. Robust Smartphone App Identification via Encrypted Network Traffic Analysis. IEEE Transactions on Information Forensics and Security 13, 1 (2018), 63–78.

[35] Thijs van Ede, Riccardo Bortolameotti, Andrea Continella, Jingjing Ren, Daniel J. Dubois, Martina Lindorfer, David R. Choffnes, Maarten van Steen, and Andreas Peter. 2020. FlowPrint: Semi-Supervised Mobile-App Fingerprinting on Encrypted Network Traffic. In Annual Network and Distributed System Security Symposium.

[36] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is All You Need. In the International Conference on Neural Information Processing Sys-tems. 6000–6010.

[37] Kailong Wang, Junzhe Zhang, Guangdong Bai, Ryan K. L. Ko, and Jin Song Dong. 2021. It's Not Just the Site, It's the Contents: Intra-domain Fingerprinting Social Media Websites Through CDN Bursts. In The Web Conference. 2142–2153.

[38] Pan Wang, Shuhang Li, Feng Ye, Zixuan Wang, and Moxuan Zhang. 2020. PacketCGAN: Exploratory Study of Class Imbalance for Encrypted Traffic Classification Using CGAN. In IEEE International Conference on Communications. 1–7.

[39] Wei Wang, Ming Zhu, Xuewen Zeng, Xiaozhou Ye, and Yiqiang Sheng. 2017. Malware Traffic Classification Using Convolutional Neural Network for Representation Learning. In International Conference on Information Networking. 712–717.

[40] Zhengyan Zhang, Xu Han, Zhiyuan Liu, Xin Jiang, Maosong Sun, and Qun Liu. 2019. ERNIE: Enhanced Language Representation with Informative Entities. In the Conference of the Association for Computational Linguistics. 1441–1451.

[41] Zhe Zhao, Hui Chen, Jinbin Zhang, Xin Zhao, Tao Liu, Wei Lu, Xi Chen, Haotang Deng, Qi Ju, and Xiaoyong Du. 2019. UER: An Open-Source Toolkit for Pre-training Models. In the Conference on Empirical Methods in Natural Language Processing. 241–246.

[42] Wenbo Zheng, Chao Gou, Lan Yan, and Shaocong Mo. 2020. Learning to Classify: A Flow-Based Relation Network for Encrypted Traffic Classification. In The Web Conference. 13–22.

另一项比较研究

A.1 定性分析

为了进一步评估模型之间的性能差异，我们选择了5个模型与ET-BERT进行比较分析，包括流级Transformer、包级Transformer、DF、Deeppacket和PERT。变压器模型作为ET-BERT的基线可以直观地比较我们预训练模型的改进，其余三个模型是比较我们模型突出性的代表性方法。

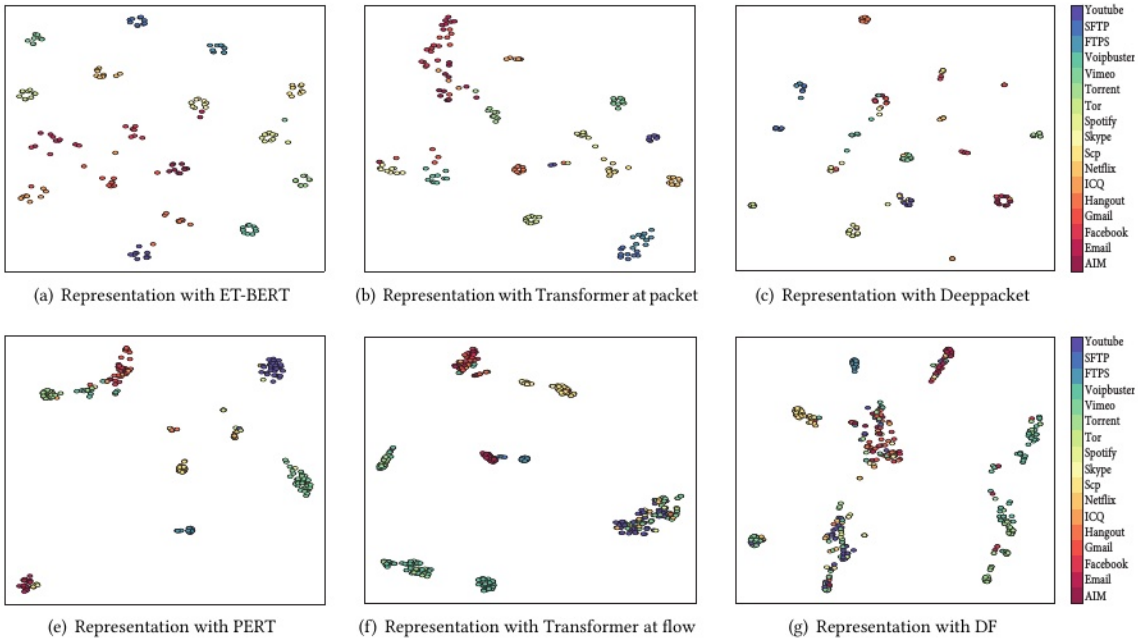

图5:t-SNE ISCX-VPN-App测试集上6种分类边界可视化方法

我们使用t分布随机邻居嵌入(t-SNE)来缩小每个模型预测的测试集样本，并将它们绘制为二维图像，如图5所示。我们在第4.3节中选择采样的ISCX-VPN-App数据集，然后显示每个模型的最佳结果:(a-c)是包级结果，(e-g)是流级结果。

毫无疑问，我们的模型展示了最好的分类性能，因为ET-BERT捕获的模式可以区分不同的加密流量，即使在更安全的新加密协议下。同样由于ET-BERT是在包级别，(b)和(c)不能准确地对应用进行分类，尤其是AIM、ICQ和Gmail，这些应用主要用于在线聊天，Gmail除了提供电子邮件服务外，还提供在线聊天服务。在流量层面，(f)和(g)的分类效果令人困惑，因为这些方法无法区分YouTube和Vimeo、Netflix、Spotify等流媒体应用程序，而PERT表现相对较好，但仍然受到具有相同服务的应用程序的干扰。